

TUGAS ASSIGNMENT MINGGU 14
KLASIFIKASI CITRA DENGAN CNN DARI AWAL HINGGA
TRANSFER LEARNING

202523430040



OLEH:

Syifa Adilla Sukma

24343128

Dosen Pengampu:

Dr. Yasdinul Huda, S.Pd., M.T.

TEKNIK INFORMATIKA
DEPARTEMEN ELEKTRONIKA
FAKULTAS TEKNIK
UNIVERSITAS NEGERI PADANG

2026

BAB 1

PENDAHULUAN

1. Latar Belakang

Perkembangan teknologi pengolahan citra digital (*digital image processing*) dan kecerdasan buatan telah membawa perubahan besar dalam cara komputer memahami informasi visual. Salah satu tantangan utama dalam bidang *computer vision* adalah bagaimana mengklasifikasikan objek di dalam gambar secara akurat menyerupai kemampuan kognitif manusia. Dahulu, ekstraksi fitur citra dilakukan secara manual menggunakan metode konvensional yang membutuhkan waktu lama dan sangat bergantung pada domain keahlian tertentu.

Kehadiran *Deep Learning*, khususnya arsitektur *Convolutional Neural Network* (CNN), menjadi sebuah terobosan besar. CNN memungkinkan proses ekstraksi fitur dan klasifikasi dilakukan secara otomatis dalam satu kesatuan jaringan end-to-end. Meskipun demikian, melatih model CNN dari awal (*from scratch*) sering kali menghadapi kendala besar, seperti kebutuhan komputasi yang tinggi, waktu pelatihan yang lama, serta risiko terjadinya *overfitting* apabila data yang digunakan terbatas.

Untuk mengatasi permasalahan tersebut, dikembangkanlah metode *Transfer Learning* dan teknik *Data Augmentation*. Praktikum ini dilakukan untuk mengeksplorasi efektivitas arsitektur CNN dasar, menganalisis pengaruh manipulasi data, serta menguji performa beberapa arsitektur *pre-trained model* ternama berbasis *Transfer Learning* menggunakan dataset referensi CIFAR-10.

2. Tujuan Pratikum

- Memahami prinsip kerja dan arsitektur dasar jaringan *Convolutional Neural Network* (CNN) untuk pengolahan citra digital.
- Menganalisis implementasi teknik *Data Augmentation* dalam mengatasi kendala *overfitting* serta meningkatkan kemampuan generalisasi model.
- Menerapkan dan membandingkan performa klasifikasi model CNN yang dibangun dari awal (*from scratch*) dengan model berbasis *Transfer Learning* seperti VGG16, ResNet50, dan MobileNetV2.
- Mampu menganalisis visualisasi *learning curve* dan *feature maps* untuk mengetahui karakteristik performa model deep learning.

BAB II

LANDASAN TEORI

2.1 Convolutional Neural Network (CNN)


Convolutional Neural Network (CNN) merupakan varian dari *Neural Network* yang dirancang secara khusus untuk memproses data berstruktur grid dua dimensi, seperti pada citra digital. Tidak seperti *Multilayer Perceptron* (MLP) konvensional yang meratakan gambar sejak awal sehingga kehilangan informasi spasialnya, CNN bekerja dengan cara mempertahankan hubungan spasial antar piksel melalui ekstraksi fitur bertahap. Operasi utama pada CNN terbagi ke dalam beberapa lapisan penyusun:

- **Convolutional Layer (Lapisan Konvolusi):** Lapisan ini menerapkan operasi konvolusi matematis dengan menggeser filter (*kernel*) berukuran kecil di atas citra input. Tujuannya adalah mengekstraksi representasi fitur-fitur visual tertentu seperti garis vertikal/horizontal, tepi objek, warna, hingga tekstur dasar.
- **Pooling Layer (Lapisan Reduksi):** Berfungsi untuk memperkecil ukuran dimensi spasial (lebar dan tinggi) dari *feature map* yang dihasilkan oleh lapisan konvolusi. Proses *downsampling* ini sangat penting untuk mengurangi beban komputasi jaringan, mempercepat pemrosesan, serta mencegah sensitivitas berlebih terhadap pergeseran posisi objek (*translation invariance*).
- **Fully Connected Layer (Lapisan Terhubung Penuh):** Terletak di bagian akhir arsitektur jaringan. Setelah fitur-fitur citra berhasil diekstraksi dan diratakan (*flattening*) menjadi sebuah vektor satu dimensi, lapisan ini bertindak layaknya jaringan saraf tiruan biasa yang mengaitkan fitur-fitur tersebut ke dalam label kelas prediksi akhir.

2.2 Dataset CIFAR-10

Dataset CIFAR-10 merupakan salah satu dataset penanda acuan (*benchmark*) yang sangat populer dalam dunia riset visi komputer dan machine learning. Dataset ini memiliki karakteristik teknis sebagai berikut:

- **Total Sampel & Dimensi:** Terdiri dari 60.000 gambar berwarna dengan format kanal RGB berukuran 32×32 piksel.
- **Pembagian Dataset:** Data didistribusikan secara seimbang ke dalam 50.000 gambar untuk kebutuhan pelatihan (*training data*) dan 10.000 gambar untuk pengujian performa (*testing data*).
- **Label Kelas:** Terbagi rata ke dalam 10 kelas objek yang berbeda, mencakup kategori benda mati serta makhluk hidup, yaitu:



Ukuran pikselnya yang kecil (32×32) menghadirkan tantangan tersendiri karena detail kejelasan objek cenderung terbatas, menjadikannya objek uji coba yang ideal untuk menguji ketangguhan arsitektur model deep learning.

2.3 Transfer Learning

Transfer Learning adalah sebuah paradigma dalam deep learning di mana pengetahuan (*knowledge*) yang telah diperoleh oleh suatu model saat dilatih untuk

menyelesaikan suatu tugas pada dataset skala besar (misalnya ImageNet dengan jutaan gambar), ditransfer dan dimanfaatkan kembali untuk menyelesaikan tugas baru yang serupa pada dataset yang berbeda (seperti CIFAR-10).

Pendekatan ini sangat efektif karena model *pre-trained* sudah memiliki filter ekstraksi fitur tingkat tinggi yang matang. Keunggulan utama dari *Transfer Learning* meliputi:

- **Kecepatan Pelatihan:** Waktu konvergensi saat proses *training* menjadi jauh lebih singkat karena model tidak perlu membangun pemahaman visual dari nol.
- **Kebutuhan Data Lebih Sedikit:** Mampu menghasilkan akurasi tinggi meskipun data target yang tersedia berjumlah relatif sedikit.
- **Akurasi Optimal:** Membantu meningkatkan akurasi akhir karena memanfaatkan bobot filter yang sudah terbukti andal.

Pada praktikum ini, tiga jenis arsitektur *pre-trained model* yang dianalisis adalah:

- **VGG16:** Arsitektur klasik yang dicirikan oleh susunan lapisan konvolusi sederhana berulang dengan filter berukuran 3×3 .
- **ResNet50:** Model mendalam yang memanfaatkan *residual/skip connection* untuk mengatasi fenomena *vanishing gradient* pada jaringan saraf yang sangat dalam.
- **MobileNetV2:** Arsitektur yang dirancang secara khusus untuk perangkat komputasi ringan (seperti *mobile* atau *embedded system*) dengan memanfaatkan operasi *depthwise separable convolution* guna meminimalkan ukuran parameter tanpa mengorbankan akurasi secara drastis.

2.4 Data Augmentation

Data Augmentation (Augmentasi Data) merupakan suatu teknik manipulasi buatan yang diterapkan pada dataset pelatihan untuk memperbanyak kuantitas dan variasi representasi gambar tanpa mengambil sampel data riil baru di lapangan. Teknik augmentasi dilakukan dengan menerapkan transformasi geometris acak pada gambar asli, antara lain:

- **Rotation:** Memutar posisi gambar pada sudut tertentu.
- **Zoom:** Memperbesar atau memperkecil skala fokus objek gambar.
- **Horizontal Flip:** Membalikkan orientasi gambar secara horizontal (kiri ke kanan).

- **Width & Height Shift:** Menggeser posisi piksel gambar secara horizontal maupun vertikal.
- **Shear:** Mengubah sudut kemiringan perspektif objek pada citra.

Penerapan augmentasi memaksa model untuk tidak hanya menghafal posisi piksel kaku dari gambar *training*, melainkan memahami substansi bentuk asli objek tersebut. Hal ini berkontribusi signifikan dalam meminimalkan *overfitting*, memperkaya variasi data, serta meningkatkan kemampuan generalisasi model saat dihadapkan pada data pengujian baru yang belum pernah dilihat sebelumnya.

BAB III

HASIL DAN ANALISIS

3.1 Perbandingan Kinerja Antar Model

Berdasarkan serangkaian uji coba simulasi yang telah dijalankan, didapatkan performa komparatif yang komprehensif dari masing-masing arsitektur jaringan yang diuji:

Kategori Model	Nama Arsitektur	Tingkat Akurasi Akhir	Kecepatan Proses Training	Ukuran File & Parameter
Scratch Model	CNN From Scratch	Baik	Sedang	Kecil
Pre-trained (TL)	VGG16	Sangat Baik	Cepat	Besar
Pre-trained (TL)	ResNet50	Sangat Baik	Sedang	Besar
Pre-trained (TL)	MobileNetV2	Baik	Sangat Cepat	Kecil

3.2 Analisis Kurva Pembelajaran (Learning Curve)

Melalui grafik *Learning Curve* yang dipantau sepanjang siklus epoch, diperoleh interpretasi performa sebagai berikut:

- Tren Akurasi: Nilai *training accuracy* menunjukkan pola peningkatan yang konsisten seiring bertambahnya interaksi epoch pelatihan. Di sisi lain, nilai *validation accuracy* bergerak naik lalu mendatar secara stabil.
- Evaluasi Overfitting: Eksperimen awal tanpa regulasi rentan memicu *overfitting* (di mana akurasi *training* tinggi tetapi akurasi *validation* jeblok). Namun, berkat integrasi lapisan Dropout serta aplikasi Data Augmentation, ketimpangan atau gap nilai antara data *training* dan *validation* dapat diperkecil secara signifikan, sehingga model menjadi jauh lebih stabil.

3.3 Analisis Efek Data Augmentation

Penggunaan teknik augmentasi memberikan dampak langsung pada ketahanan model:

- Tanpa augmentasi, model cenderung cepat mengalami stagnasi (*stuck*) dan menghafal detail piksel latar belakang citra.
- Dengan menstimulasi variasi geometri baru (seperti pembalikan arah dan pergeseran posisi), *validation accuracy* terbukti mengalami eskalasi peningkatan. Model dilatih untuk tetap mengenali objek utamanya (misal: mobil atau pesawat) meskipun posisinya miring, bergeser, atau terpotong sebagian.

3.4 Visualisasi Feature Maps & Proses Fine-Tuning

- Feature Maps Interpretation: Hasil ekstraksi visual pada lapisan-lapisan awal (*shallow layers*) dari CNN memperlihatkan filter aktif bekerja mengidentifikasi komponen primitif citra seperti guratan garis, sudut tajam, orientasi tepi, dan tekstur dasar kasar. Ketika representasi masuk ke lapisan yang lebih dalam (*deep layers*), fitur dasar tersebut digabungkan secara otomatis membentuk geometri objek yang kompleks dan menyerupai wujud utuh target kelas.
- Analisis Fine-Tuning: Metode *Fine-Tuning* diterapkan dengan membuka beberapa lapisan teratas model *pre-trained* untuk ikut dilatih kembali menggunakan dataset CIFAR-10. Dalam proses ini, pemilihan nilai parameter *learning rate* yang sangat kecil menjadi kunci krusial. *Learning rate* kecil menjaga agar bobot penting (*weights*) yang sudah terbentuk kokoh dari dataset ImageNet tidak rusak mendadak, melainkan bergeser secara halus dan adaptif menyesuaikan distribusi data baru CIFAR-10.

BAB IV

KESIMPULAN

Berdasarkan seluruh tahapan implementasi, pengujian, serta analisis komparasi yang telah dilakukan dalam praktikum ini, diperoleh kesimpulan sebagai berikut:

1. Arsitektur **Convolutional Neural Network (CNN)** terbukti sangat efektif dan andal dalam menyelesaikan studi kasus klasifikasi citra digital multisampel pada dataset CIFAR-10.
2. Implementasi metode **Transfer Learning** (terutama dengan arsitektur **VGG16**) terbukti memberikan efisiensi performa terbaik dengan menghasilkan akurasi klasifikasi yang jauh lebih tinggi, waktu proses komputasi pelatihan yang lebih singkat, serta minim kendala keterbatasan data.
3. Teknik **Data Augmentation** terbukti secara empiris bertindak sebagai regulasi yang ampuh dalam mereduksi gejala *overfitting*, memperkecil selisih eror antara data latih dan data uji, serta melatih tingkat sensitivitas generalisasi model agar mampu mengenali data baru di luar dataset dengan akurasi yang lebih presisi.

link github

<https://github.com/Syifa0513/Tugas14>